

# 推荐系统之召回：基本原理和前沿研究

Dr. Bin Fu

[binfu@pku.edu.cn](mailto:binfu@pku.edu.cn)

2023-09

# 召回

- 意义：


- 从海量的候选集合中发现用户当前感兴趣或相关的物品集合（几百到几千），过滤掉绝大多数不喜欢的物品。
- 考虑召回通道的多样性和高覆盖率，对时延有一定要求，低准确率要求（折中）。
- 趋势：目前双塔模型占主流，近几年召回学习模型越来越复杂（复杂程度逼近排序模型），有召回+排序融合或联合训练趋势。



# 召回策略

- 常用策略：

- 非个性化召回：地理召回、热门召回等。
- 类目、标签、关键词召回。
- 聚类召回
- Look-Alike和社交关系召回
- 行为路径模式召回：看了又看、搜了又搜等。
- 协同过滤（冷启动问题）
- 知识图谱召回
- 双塔模型
- 多兴趣召回模型
- 召回学习模型负采样和去重
- 多目标召回学习模型
- 与业务相关的召回策略
- 未来探索方向



# 非个性化召回

- 规则策略:

- 地理召回
- 热门召回

.....

- 过滤:

- 疲劳降权
- 黑白名单过滤
- 内容低质量过滤

.....

# 类目、标签、关键词召回

- 召回细节(u2c2i):

- 原理: 用户画像 -> 类目/标签/关键词 -> 物品。(考虑时间)
- 离线建立用户画像索引库和物品画像索引库。
- 在线根据用户得到物品兴趣偏好列表。

# 内容相似（聚类）召回


- 召回细节(u2c2i):

- 原理：用户最近喜欢的物品  $\rightarrow$  查找相似内容（类）  $\rightarrow$  物品。
- 离线训练内容相似度模型，如文本BERT、图像CNN（以及考虑跨模态检索），根据物品内容相似度对物品聚类，构建向量索引。
- 在线获取用户近期感兴趣的 $n_1$ 个物品，检索其内容相似物品(约 $n_1 k$ 个)，计算其兴趣分数。
- 在线按照兴趣分数进行排序取top- $n_2$ 个物品召回。

# Look-Alike和社交关系召回

- 召回细节 (i2u2u) :


- 原理: 物品的种子用户  $\rightarrow$  相似用户。
- 离线计算用户之间的相似度, 建立“用户  $\rightarrow$  (top- $k$ 相似) 用户”索引。
- 在线获取物品最近点击用户, 根据这些种子用户获取其top- $k$ 相似用户集合。



# 协同过滤

- ItemCF/Swing (u2i2i) :

- 原理:  $\sum_i like(user, item_i) \times sim(item_i, item)$
- 离线计算物品相似度, 可采用Jaccard系数、余弦、Swing ( $sim(i, j) = \sum_{u_1 \in V} \sum_{u_2 \in V} \frac{1}{\alpha + overalp(u_1, u_2)}$ ) 等相似度, 建立“物品 -> (top-k相似) 物品”索引。
- 在线获取用户近期感兴趣的 $n_1$ 个物品, 检索其相似物品(约 $n_1 k$ 个), 计算其兴趣分数。
- 在线按照兴趣分数进行排序取top- $n_2$ 个物品召回。

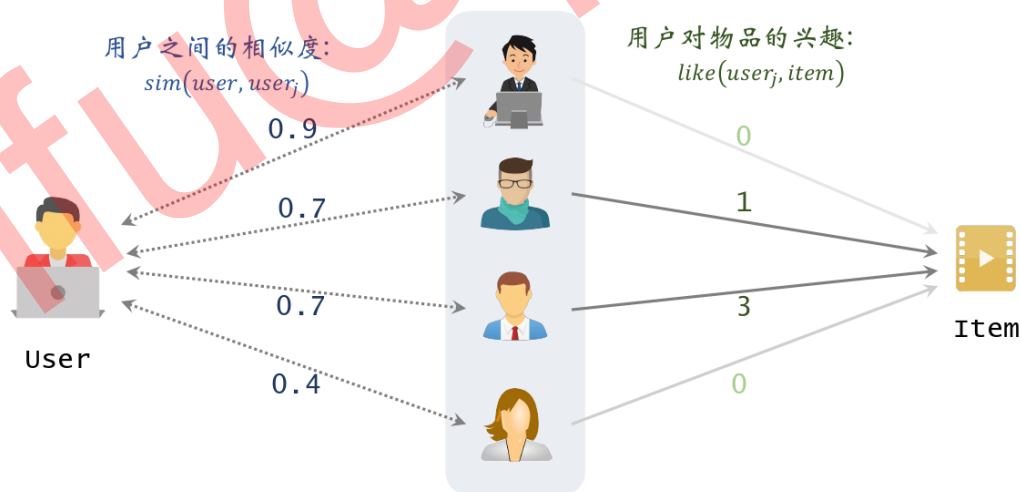




# 协同过滤

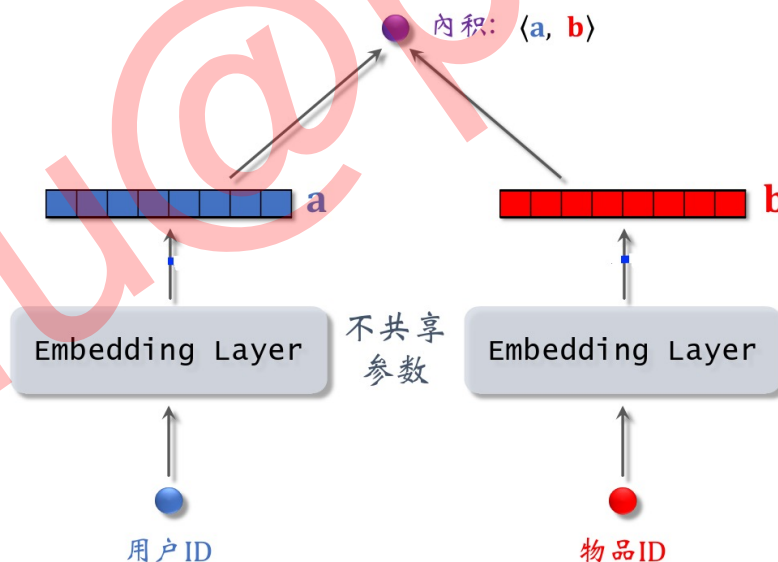
- UserCF (u2u2i):

- 原理:  $\sum_i sim(user, user_j) \times like(user_j, item)$ , 在相似度计算中可进一步对热门物品降权  $1 \rightarrow \frac{1}{\lg(1+n)}$ 。
- 离线建立“用户-> (最近交互过) 物品”索引。
- 离线计算用户之间的相似度, 建立“用户-> (top-k相似) 用户”索引。
- 在线获取用户的top-k相似用户集合, 找到用户感兴趣的物品集合。
- 在线按照兴趣分数进行排序取top- $n_2$ 个物品召回。



# 协同过滤

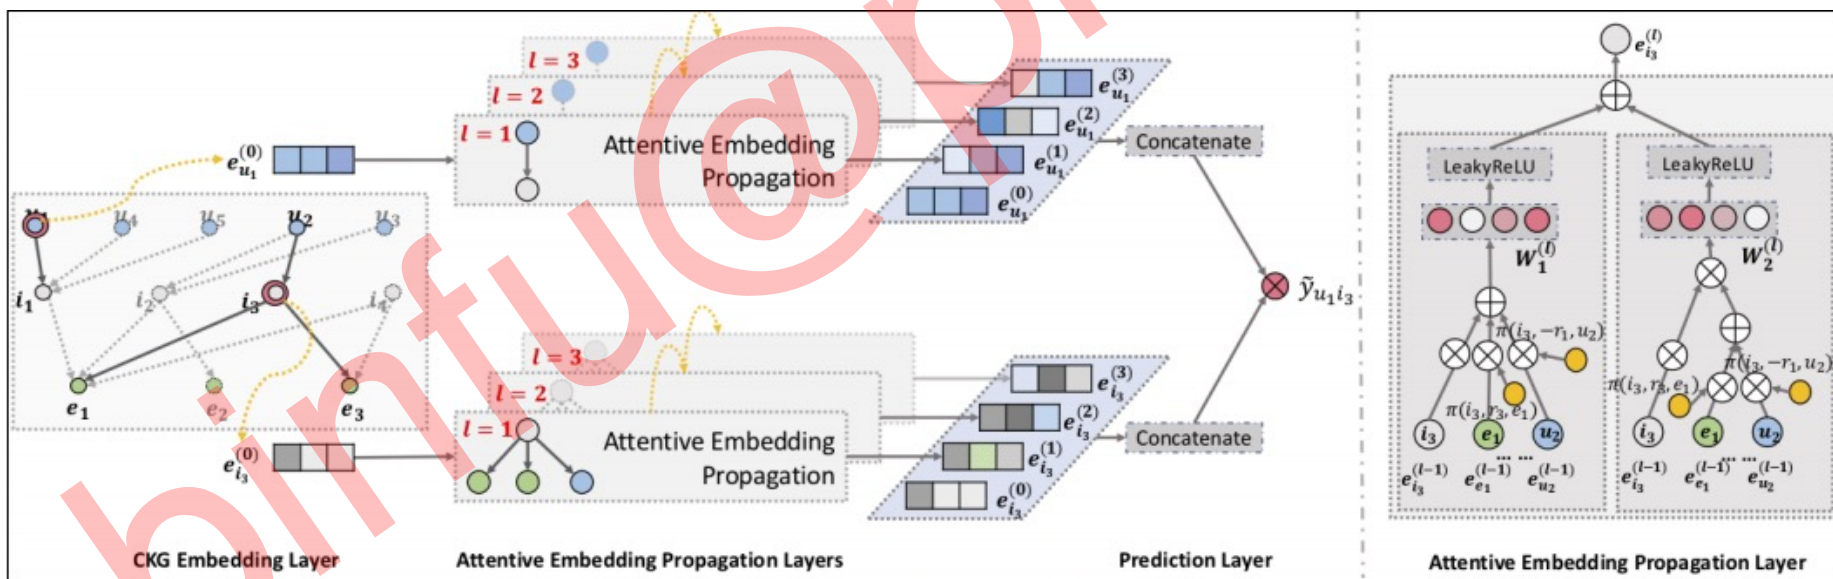
- 矩阵填充：（u2i，实践中一般效果不好）
  - 原理：矩阵分解方法MF、PMF、NMF、SVD。
  - 离线进行矩阵分解得到用户侧嵌入和物品侧嵌入，并建立向量索引（如Faiss）。
  - 在线通过用户嵌入进行最近邻查找找到用户感兴趣的物品集合。
  - 在线按照兴趣分数进行排序取top- $n_2$ 个物品召回。



# 知识图谱召回

- 知识图谱召回 (u2g2i) :

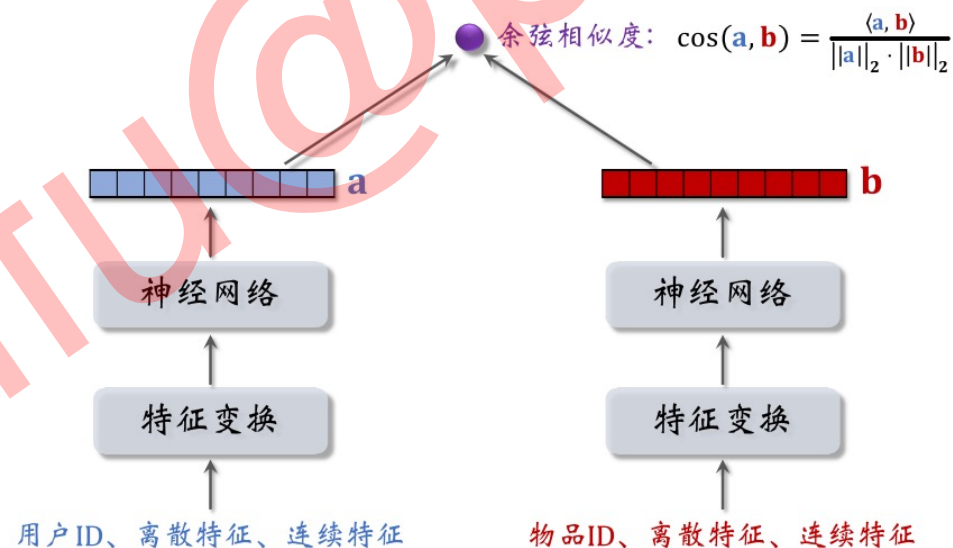
- 原理: 基于知识图谱发现用户节点触达的物品。
- 离线进行矩阵分解得到用户侧嵌入和物品侧嵌入, 并建立向量索引 (如Faiss)。
- 在线通过用户嵌入进行最近邻查找找到用户感兴趣的物品集合。
- 在线按照兴趣分数进行排序取top- $n_2$ 个物品召回。



# 双塔模型

- 匹配模型 (u2i) :


- 损失函数: 点 (交叉熵)、对 (BPR loss / triplet hinge loss)、列表。
- 正负样本: 正样本为用户点击物品, 负样本可为没有被召回和排序被淘汰掉的物品。
- 离线训练得到用户侧嵌入和物品侧嵌入, 并建立向量索引 (如Faiss)。
- 在线通过用户嵌入进行最近邻查找找到用户感兴趣的物品集合。
- 在线按照兴趣分数进行排序取top- $n_2$ 个物品召回。



# 双塔模型

- 问题：

- 长尾物品的表征学的差。
- 利用自监督学习来增强表征，随机mask部分特征进行预测。
- 附加一个自监督损失。



# 双塔模型

- 改进:
  - 特征交叉
  - 模型集成

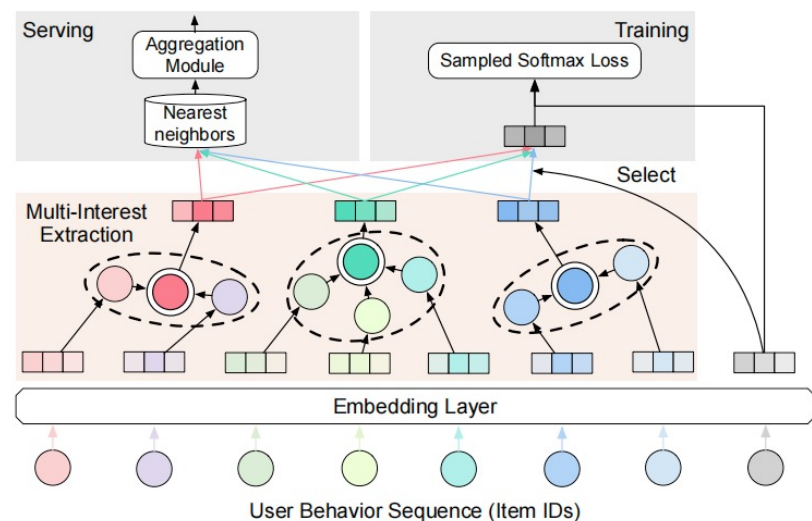
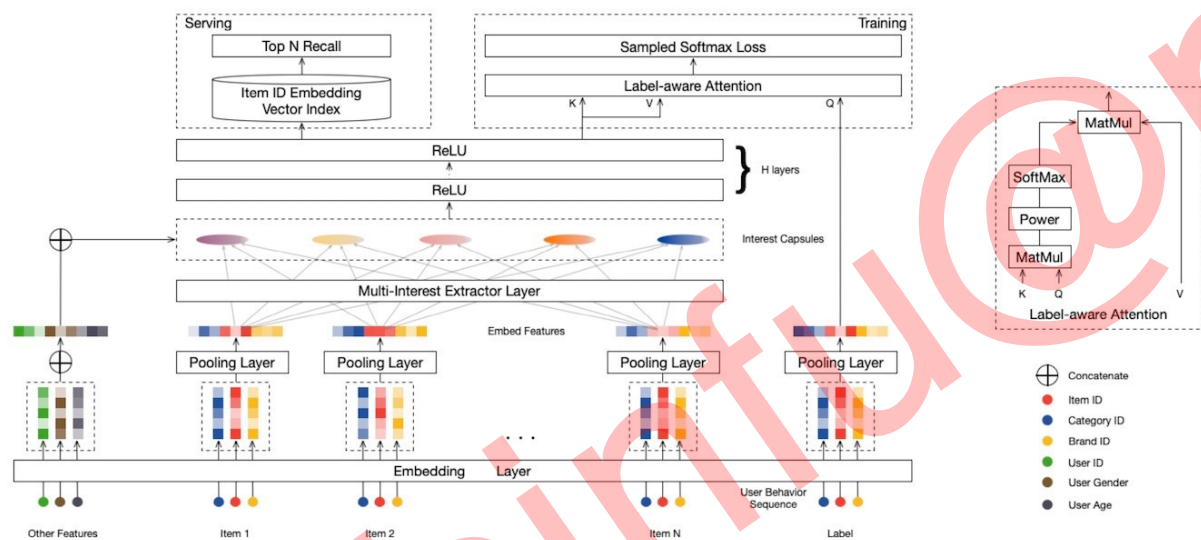




# 多兴趣召回模型

- 多兴趣召回学习模型（u2i & i2i）：

- 原理：挖掘用户行为序列中存在多种兴趣偏好，召回走top- $k$ 路由通路（软聚类）。
- MIND：采用胶囊网络来建模多个兴趣点，采用其路由机制映射到对应兴趣点。
- ComiRec：通过自注意力机制从行为序列中得到用户的多个兴趣点。



Multi-Interest Network with Dynamic Routing for Recommendation at Tmall, 2019.

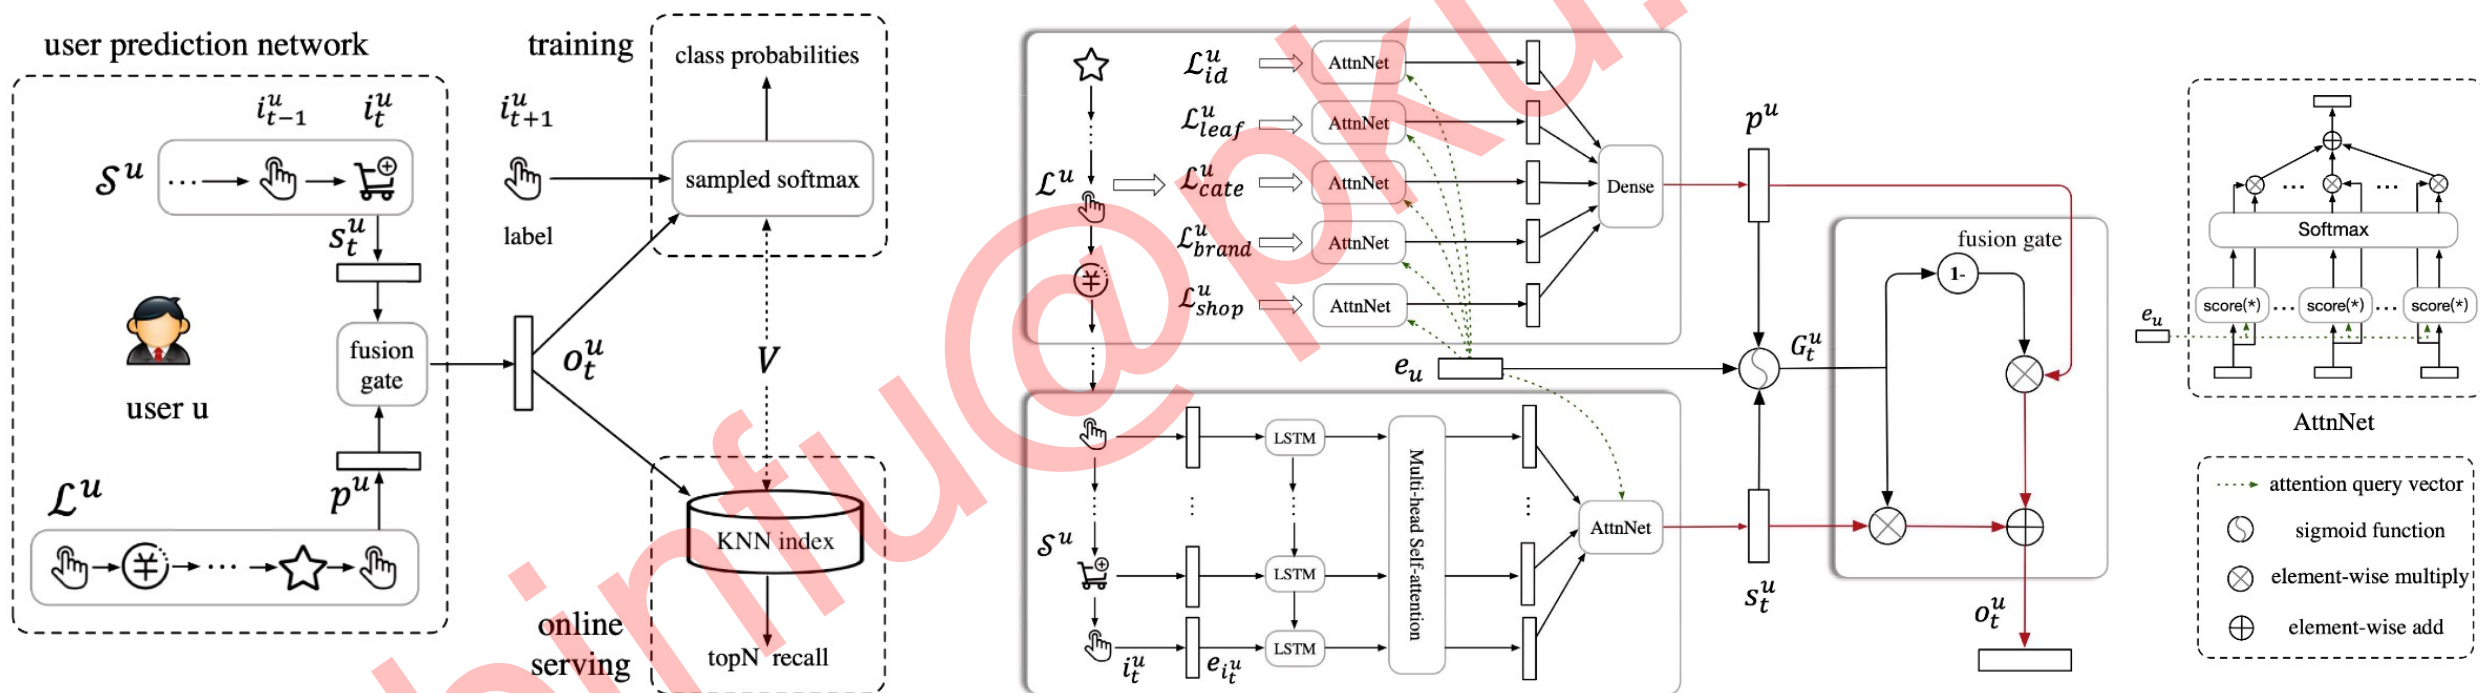
Controllable Multi-Interest Framework for Recommendation, KDD 2019.

Sparse-Interest Network for Sequential Recommendation, WSDM 2021.

Multi-task Learning Model based on Multiple Characteristics and Multiple Interests for CTR prediction, 2022.

# 多兴趣召回模型

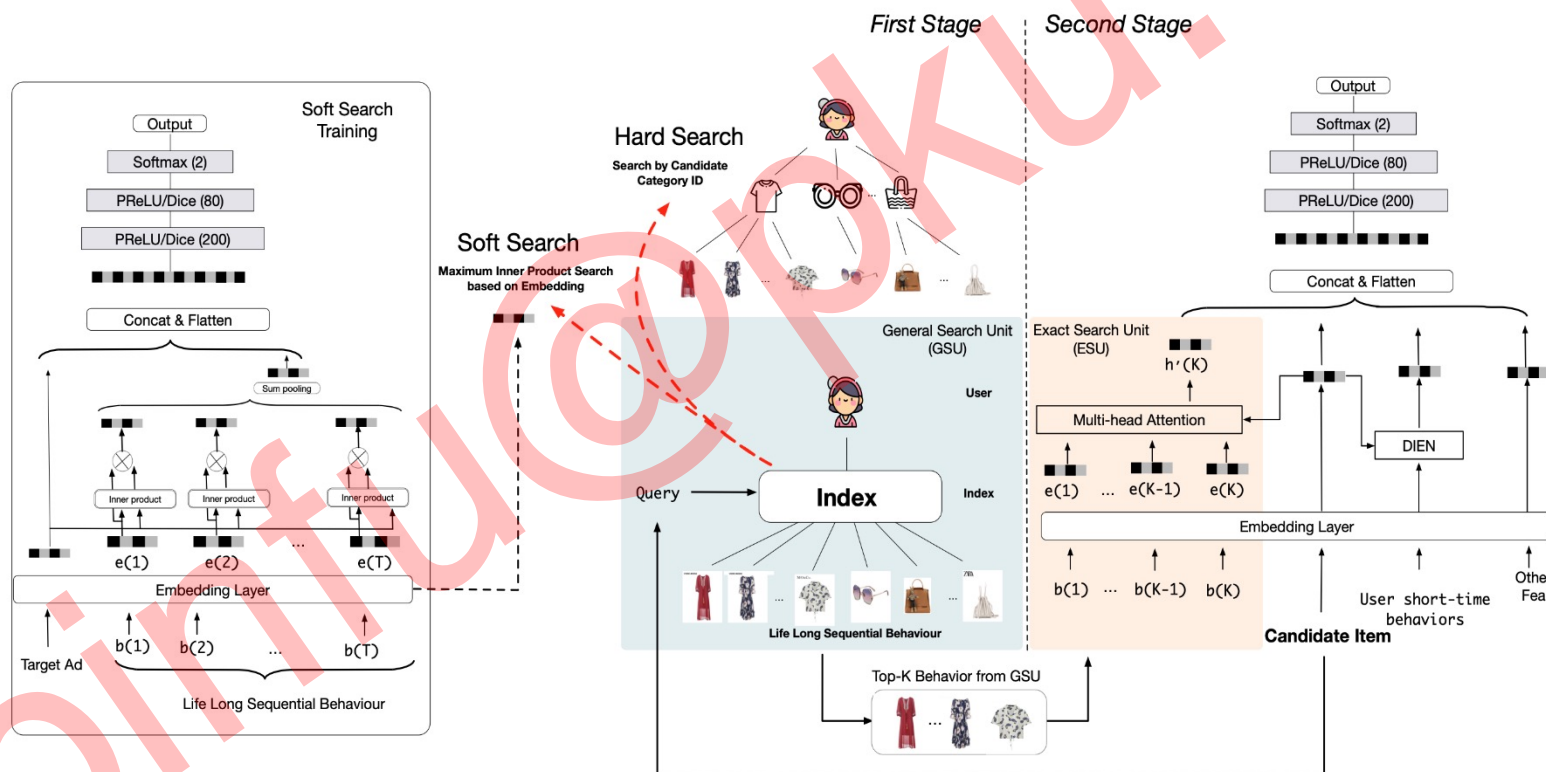
- 多兴趣召回学习模型 (u2i & i2i) :
  - SDM: 挖掘长短期兴趣偏好, 七天行为和当前session内行为。





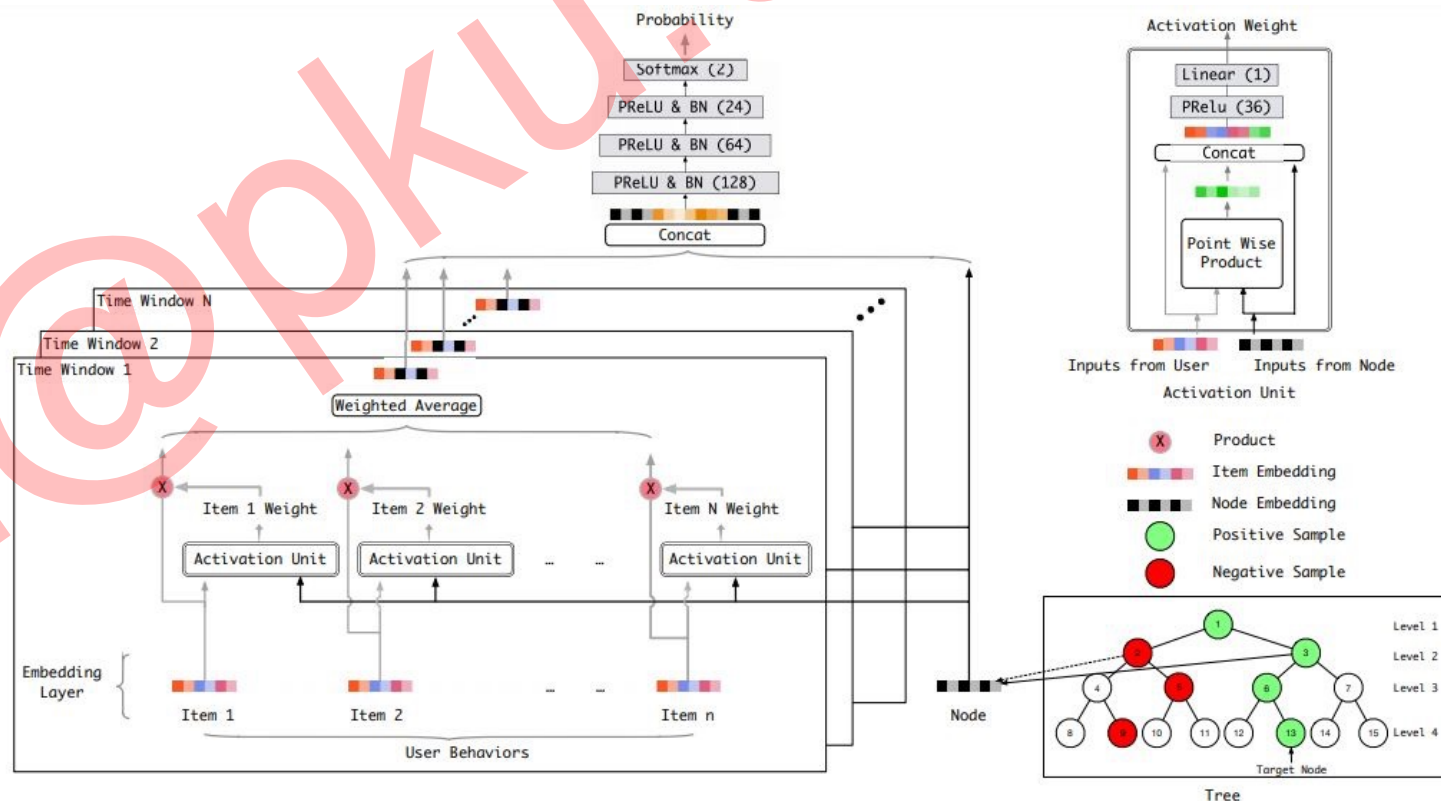

# 多兴趣召回模型

- 多兴趣召回学习模型 (u2i & i2i) :
  - SIM: 从用户历史行为序列中检索与target item最相似top-k的历史物品。



# 多兴趣召回模型

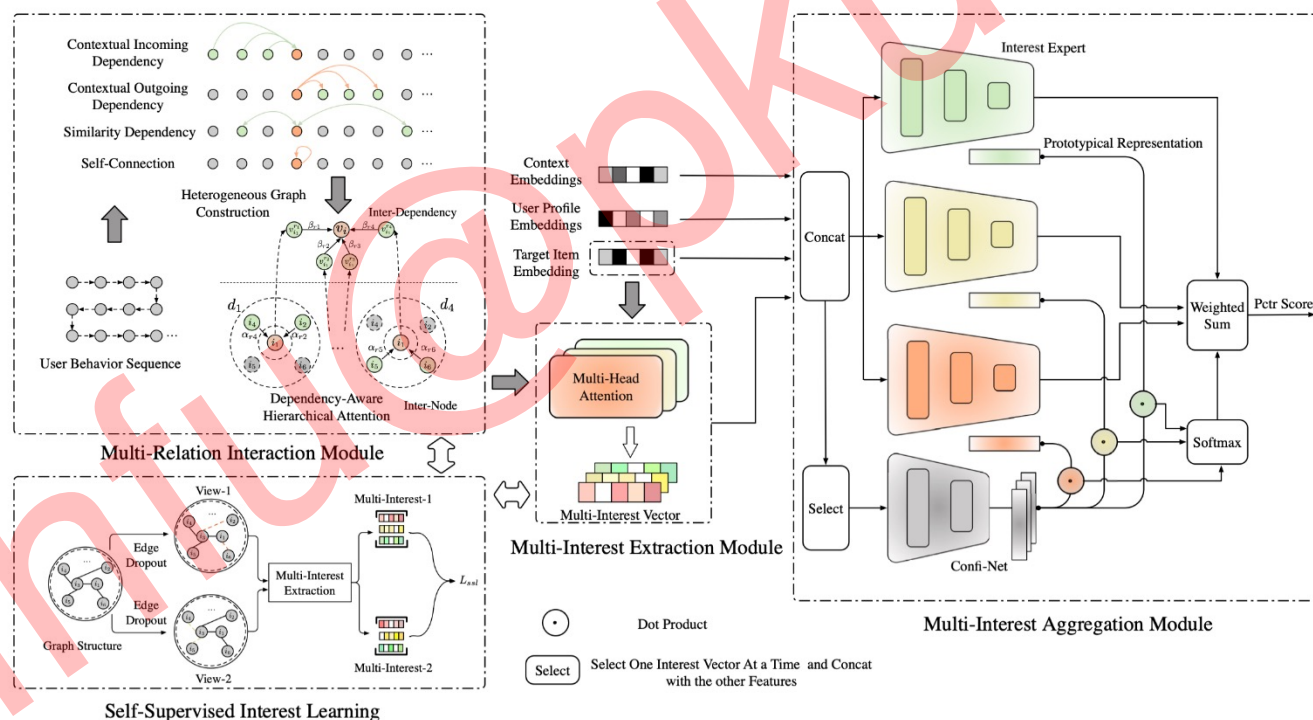
- 多兴趣召回学习模型 (u2i & i2i) :
  - 深度树匹配模型TDM: 用户兴趣度量进行层次化建模与beamsearch检索。



# 多兴趣召回模型

- 多兴趣召回学习模型 (u2i & i2i) :

- DemiNet: 用户行为序列存在噪音和稀疏问题 (自监督) 且多个兴趣点存在关系。
- MISS: 用户行为序列上的特征 (行) 和兴趣 (列, 相邻行为CNN) 级别自监督学习。

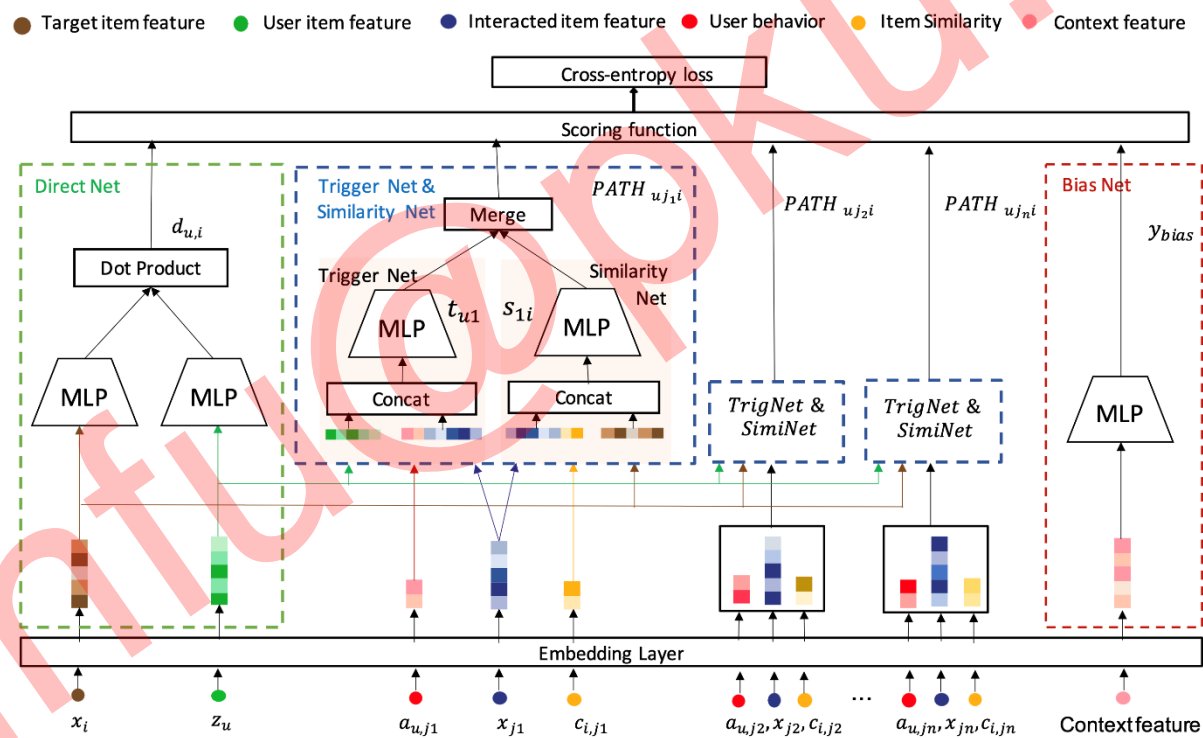


DemiNet: Dependency-Aware Multi-Interest Network with Self-Supervised Graph Learning for Click-Through Rate Prediction, AAAI 2022.

MISS: Multi-Interest Self-Supervised Learning Framework for Click-Through Rate Prediction, ICDE 2022.


# 混合召回模型

- 混合召回学习模型（u2i & i2i）：
  - PDN：集合双塔模型和i2i历史行为序列模型。



# 多目标召回学习模型

- 多目标:
  - 需要兼顾效率和效果，一般模型设计较为简单些。



# 召回学习模型负采样和去重

- 负样本：
  - 简单负样本：未被召回的物品，占绝大多数，几乎为全体物品。（50%）
  - 困难负样本：排序淘汰的物品。（50%）
  - 极困难负样本：曝光未点击的物品，用户喜欢但未点击不能作为召回负样本，损害召回性能。
- 负采样策略：
  - 热度采样：如  $p \propto pv^{0.75}$ 。采样概率可转化为权重。
  - Batch内负采样。
  - 其他策略：地域敏感进行地域采样（同城、商圈等）、
- 曝光去重复：
  - Bloom 过滤器：多个哈希映射函数，没命中一定不在曝光集合。

# 召回阶段训练流程

- 数据特征预处理
  - 获取并过滤T+2天离线数据（spark/hive实现，根据业务特点设计T，如BOSS直聘采用7+2）。
  - 构建特征集（验证特征有效性）。
  - 构建正负样本集（不同采样比例）。
- 模型分布式训练
  - 基于TF2.0或pytorch实现模型。
  - 在分布式集群或者多GPU卡训练（模型一般迭代2~3轮就会收敛，耗时几小时）。
  - 调优模型（特征工程+模型架构等，这部分耗时较长）并评估效果。
  - 保存模型训练过程日志和模型文件（包括嵌入表并利用Faiss/ES等ANN工具构建索引）。
- 在线推理：
  - 利用RPC调用模型服务TF-serving。
  - 实时特征获取、拼接和推理。



## 其他召回策略

- 分层召回

- 物理维度：城市、业务等。
- 用户分群：会员和非会员等。

.....



# 未来探索方向

- 随着算力暴力提升，召回模型越来越复杂，融合后
- 深挖各种召回模式路径并进行有效组合，考虑多样
- 模型结构探索，多目标多任务条件下探索等。
- 用户历史行为序列中多兴趣挖掘和快速检索等。
- 构建更高质量的负样本。
- 长尾物品和新/低活用户冷启动问题。
- B端和C端的优化目标、生态调控，深挖系统优化
- 基于大语言模型（LLM）的召回研究。